

卒業論文

金型空間内の不良成形品ピックアップのための  
画像認識を用いたロボットシステムの検討

F116056 三木 康平

指導教員 永田寅臣 教授

2020 年 3 月

山口東京理科大学 工学部 機械工学科



概要



# 目次

第 1 章	緒言	1
第 2 章	運動学	2
2.1	順運動学 . . . . .	2
2.2	逆運動学 . . . . .	4
第 3 章	画像認識	7
3.1	画像処理 . . . . .	7
3.2	2 つの閾値を用いた二値化処理 . . . . .	8
3.3	Canny 法を用いたオブジェクト抽出 . . . . .	9
第 4 章	人工知能	11
4.1	人工知能 . . . . .	11
4.2	機械学習 . . . . .	11
4.3	深層学習 . . . . .	12
4.4	ニューラルネットワーク . . . . .	12
4.5	コスト関数 . . . . .	16
4.6	畳み込みネットワーク . . . . .	16
第 5 章	実機による動作実験	17
5.1	Dobot . . . . .	17
5.2	学習データ . . . . .	17
5.3	実験結果 . . . . .	17
第 6 章	今後の方針	18
	謝辞	19
	参考文献	20



# 第 1 章

## 緒言

近年, 消費者嗜好の多様化により, 商品生産方式が少品種大量生産から変種変量生産へと変わってきている. それに応じて, ロボットも単一工程に特化した産業用ロボットから, 人のように状況判断を行い, 幅のある業務をこなすことができるような汎用機械としてのロボットへと, ニーズが変化してきている [1]. このニーズに応えるため, さまざまな画像処理を自動で行うカメラや, ベルトコンベア上の製品を自動で仕分けするロボットビジョンなどが販売されているが, カメラや光源の位置が限られる狭い空間内において, 対象物を画像処理により検出し移動させるシステムの実現は難しい. そこで, 研究室では狭い空間内での正確な物体の検出および移動を最終的な目標としたシステムの研究を行っている. 本研究では, 現在取り組んでいるシステムの進捗について報告する.

課題に取り組むに当たって, まず開けた空間内に平面に置かれた物体を画像認識により, 対象物の角度を依らず, 正確にピック&プレースを行うロボットシステムを開発した. この手法では, 画像内に写るオブジェクトの角度を AI で推定し, アームで Picking を行う. 具体的には, 対象物をカメラにより撮影し, まず画像認識により対象物の重心位置を計算し, その位置までアームを移動させる. その後, 角度推定用に AlexNet を基に転移学習したネットワークがその角度を推定する. そして, アームに付属するエンドエフェクタを推定角度だけ回転させ, 対象物を Picking する.

## 第 2 章

# 運動学

ロボットアームの手先を目的の位置に移動させたいとき、各関節角度と関節間の長さ現在の手先位置が分かっているならば、運動学を用いて必要な姿勢を計算することが出来る。運動学とは、ロボットアームの関節角度や関節間の長さで手先位置・姿勢の関係を数式で表したものであり、各関節角度から手先位置・姿勢を求めることを順運動学、手先位置・姿勢から各関節角度を求めることを逆運動学という。また、ロボットアームは各関節ごとに座標系（関節座標系）を設定することができ、この座標系と台座部に設定した基準座標系は運動学に用いることで互いに変換することができる。

### 2.1 順運動学

順運動学とは、ロボットアームの各関節角度の変位（回転・並進）から手先位置・姿勢を求めることであり、すなわち手先位置の関節座標系から基準座標系への変換とすることができる。また、順運動学は各関節の回転と並進の要素を持つ。

#### 2.1.1 計算方法

ここでは関節座標の手先位置を基準座標系に変換する方法について示す。まず簡単のために図 2.1 のような系について考える。

移動後の原点  $O'(x'_0, y'_0, z'_0)$  は、移動前の原点  $O(x_0, y_0, z_0)$  から見ると次のように表される。

$$\begin{aligned}x'_0 &= x_0 + x_1 \\y'_0 &= y_0 + y_1 \\z'_0 &= z_0 + z_1\end{aligned}$$

上式をベクトル  $\mathbf{r}$  を用いて表すと、以下のようになる。

$$O' = O + \mathbf{r} \tag{2.1}$$

関節座標系から基準座標系への変換を行うには、並進移動だけでなく回転移動についても考える必要がある。そこで図 2.2 のような簡単な系の回転移動について考える。






Fig.2.1. Polishing scene using a conventional industrial robot with a servo spindle.




Fig.2.2. Polishing scene using a conventional industrial robot with a servo spindle.

まずベクトル  $\mathbf{P}(x_1, y_1, z_1)$  は、各軸方向の単位ベクトル  $(\mathbf{i}, \mathbf{j}, \mathbf{k})$  を用いて次のように表される.

$$\mathbf{P} = x_1\mathbf{i} + y_1\mathbf{j} + z_1\mathbf{k} \quad (2.2)$$

次に、Z 軸を基準としてベクトル  $\mathbf{P}$  を含む X-Y 平面を  $\theta$  だけ回転した座標系を新しく  $X', Y', Z'$  座標系とすると、その座標系におけるベクトル  $\mathbf{P}'(x_2, y_2, z_2)$  は単位ベクトル  $\mathbf{i}', \mathbf{j}', \mathbf{k}'$  を用いて次のように表される.

$$\mathbf{P}' = x_2\mathbf{i}' + y_2\mathbf{j}' + z_2\mathbf{k}' \quad (2.3)$$

ここで、単位ベクトル  $\mathbf{i}', \mathbf{j}', \mathbf{k}'$  は回転前の座標系から見ると

$$\begin{bmatrix} \mathbf{i}' \\ \mathbf{j}' \\ \mathbf{k}' \end{bmatrix} = \begin{bmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{i} \\ \mathbf{j} \\ \mathbf{k} \end{bmatrix} \quad (2.4)$$

と表せる. さらに式 (2.4) に式 (2.3) と式 (2.2) を代入すると

$$\begin{bmatrix} x_2 \\ y_2 \\ z_2 \end{bmatrix} = \begin{bmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \\ z_1 \end{bmatrix}$$

さらに見通しをよくするため, 単位ベクトルを省略し以下のように表す.

$$\mathbf{P}' = \begin{bmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 0 \end{bmatrix} \mathbf{P} \quad (2.5)$$

すなわち Z 軸を基準としたベクトルの回転移動は, 移動前後の位置移動および相対角  $\theta$  を用いて表すことができ, これは X 軸, Y 軸においても成り立つ. この式 (2.5) 中央の行列を回転行列といい  $R$  で表すこととする. 並進移動と回転移動とを用いることにより, 図 2.3 に示すような一見複雑な座標系の変換も次のような式で表すことができる.




Fig.2.3. Polishing scene using a conventional industrial robot with a servo spindle.

$${}^A\mathbf{P} = {}^A\mathbf{R}_B {}^B\mathbf{P} + {}^A\mathbf{r}_B \quad (2.6)$$

ここで  ${}^A\mathbf{R}_B$  は座標系 A から座標系 B への回転行列である. この関係を各関節ごとに用いることで, 手先位置を基準座標系からの位置として求めることができる.

## 2.2 逆運動学

順運動学が座標変換を行うことで解が 1 つ求まるのに対して, 逆運動学では図 2.4 の場合のように手先位置が同じ位置にある場合でも各リンクの位置と姿勢にはいくつかの解が存在することや, 解自体が存在しないこともある. このような問題があるため, 一般に順運動学より逆運動学の方が問題を解くのが難しい.

逆運動学でアームの関節角度を計算する例として, 図 2.5 のような場合を考える. まず, 角度  $\alpha$  と  $|\mathbf{OP}|$  の関係は余弦定理を用いて次式で表される.

$$\cos \alpha = \frac{L_1^2 + L_2^2 - |\mathbf{OP}|^2}{2L_1L_2} \quad (2.7)$$




Fig.2.4. Polishing scene using a conventional industrial robot with a servo spindle.




Fig.2.5. Polishing scene using a conventional industrial robot with a servo spindle.

式 (2.7) より角度  $\alpha$  は  $\alpha = \cos^{-1}(\cos \alpha)$  と表せるので, 結果的に  $\theta_2$  は次式で表される.

$$\theta_2 = \pi - \alpha \quad (2.8)$$

同様に, 余弦定理を用いて角度  $\beta$  と  $|OP|$  の関係は次式で表され,

$$\cos \beta = \frac{|OP|^2 + L_1^2 - L_2^2}{2|OP|L_1}$$

$\beta = \cos^{-1}(\cos \beta)$  である. 最後に角度  $\gamma$  は, 補助線  $|OP|$  と手先位置の  $x$  座標との関係から

$$\cos \gamma = \frac{x}{|OP|}$$

であるので,  $\gamma = \cos^{-1}(\cos \gamma)$  である. よって, 角度  $\beta$  および角度  $\alpha$  を用いて  $\theta_1$  は次式で表される.

$$\theta_1 = \gamma - \beta \quad (2.9)$$

よって, 手先位置から関節角度  $\theta_1, \theta_2$  を求めることができた.

また別の方法として, 図 2.6 のような場合を考える. この場合, 手先位置は次式で表される.

$$\begin{aligned} x_p &= l_1 \cos \theta_1 + l_2 \cos(\theta_1 + \theta_2) \\ y_p &= l_1 \sin \theta_1 + l_2 \sin(\theta_1 + \theta_2) \end{aligned} \quad (2.10)$$




Fig.2.6. Polishing scene using a conventional industrial robot with a servo spindle.

式 (2.10) の両辺を時間で微分し, 行列で表すと

$$\frac{d\mathbf{P}}{dt} = \mathbf{J}(\boldsymbol{\theta}) \frac{d\boldsymbol{\theta}}{dt} \quad (2.11)$$

ここで

$$\mathbf{P} = [x_p, y_p]^T, \boldsymbol{\theta} = [\theta_1, \theta_2]^T, \mathbf{J}(\boldsymbol{\theta}) = \begin{bmatrix} -(l_1 \sin \theta_1 + l_2 \sin(\theta_1 + \theta_2)) & -l_2 \sin(\theta_1 + \theta_2) \\ l_1 \cos \theta_1 + l_2 \cos(\theta_1 + \theta_2) & l_2 \cos(\theta_1 + \theta_2) \end{bmatrix}$$

である. 式 (2.12) は手先位置の速度と各関節における角速度の関係を表しており, 両辺の変換を担う行列  $\mathbf{J}$  を一般にヤコビ行列という. さて, 逆運動学は手先位置から各関節角度を求める問題のことであったので, 式 (2.12) を以下のように変形する.

$$\frac{d\boldsymbol{\theta}}{dt} = \mathbf{J}^{-1} \frac{d\mathbf{P}}{dt} \quad (2.12)$$

しかし,  $\mathbf{J}^{-1}$  は必ずしも存在しない.  $\mathbf{J}^{-1}$  が存在しない条件は,  $\det \mathbf{J}^{-1}$  で求めることができ, その時の姿勢を特異姿勢もしくは特異点という.

## 第 3 章

# 画像認識

物体認識は、画像認識製造業における生産ラインでのロボット視覚 (ロボットビジョン) や移動ロボットの目標追尾, 自動走行車における周辺認識など, 幅広い分野で実用化が望まれている. 文献によると, 現状の物体認識の課題は次の 2 つに大別される. 一つ目は, 対象物を正確にデータ化するための 3 次元計測に関する課題であり, 二つ目は, それをもとに対象物の位置・姿勢, 種類などを正しく認識するデータ処理に関する課題である.

### 3.1 画像処理

画像処理とは, アナログ画像処理方式とデジタル処理方式に分けられ, 前者はレンズ系や現像技術を用いて画像の特徴抽出や変換を行う手法であり, 後者は画像の濃度値を画素ごとに数値化し, 演算処理によって画像の特徴抽出や変換を行う手法である. 今回実験に用いた手法は, 後者に属するものである. 本節では, 画像の二値化処理について概説した後, アプリケーションに実装した処理方法について説明する.

#### 3.1.1 色空間

#### 3.1.2 二値化

グレースケール画像を二値化する最も基本的な処理は, 閾値を用いる方法である. すなわち, 入力画像の画素値  $I(x, y)$ , 閾値を  $\theta$  とした場合,

$$I'(x, y) = \begin{cases} 255 & \text{if } (I(x, y) \geq \theta) \\ 0 & \text{others} \end{cases} \quad (3.1)$$

によって, 画素値を決定する.

しかし, 図のようにグレー画像全体に対して単純な閾値処理をするだけでは, 模様が潰れたり濃淡構造が部分的に失われたりする. そのため, 画素値のヒストグラムの統計量 (最大値や分布など) を用いて閾値を決定する方法や, 画素ごとに閾値を変える適応的閾値処理が提案されてきた. [2, 3].

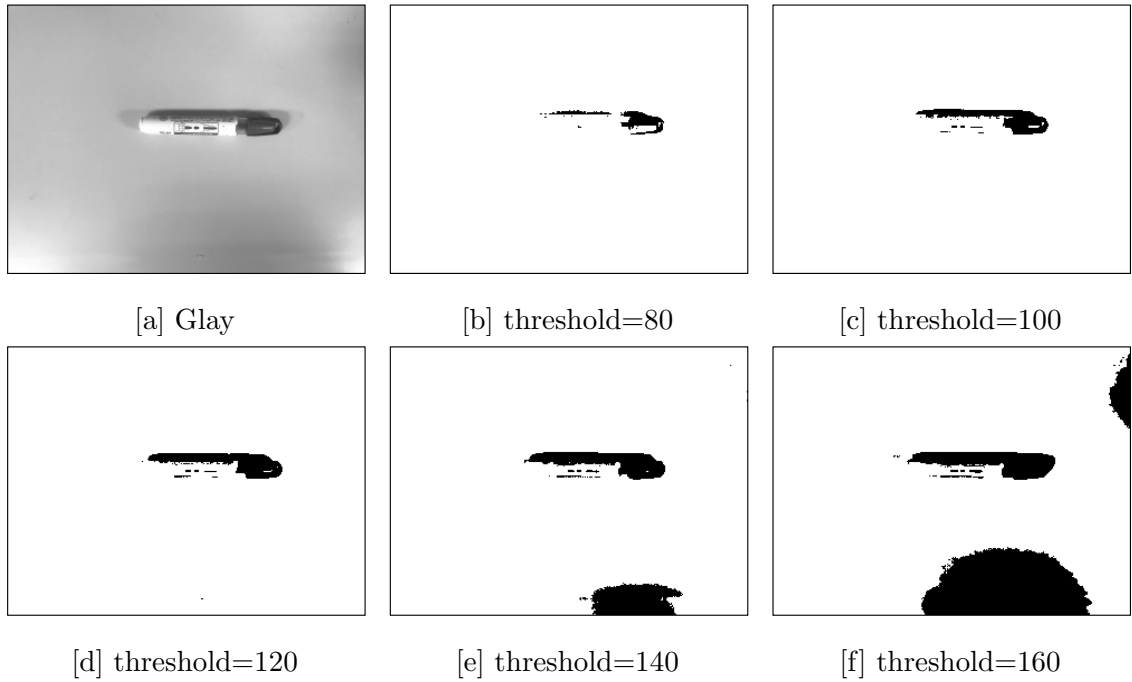


Fig.3.1. 単純二値化処理

本アプリケーションには、単純閾値処理、Bradley 法、2 つの閾値を用いた閾値処理を実装した。

### 3.1.3 Bradley 法

Bradley 法は、入力画像上の注目画素を中心とする、ある領域内 ( $s \times s$ ) の画素値の平均値を注目画素の閾値とし、その値が注目画素の画素値よりも  $t\%$  小さい場合は黒、そうでない場合は白に値を置き換える方法である。すなわち、注目画素の閾値を式 [?] にて計算し、

$$S = \frac{1}{N} \sum_{i=-\frac{s}{2}}^{i+\frac{s}{2}} \sum_{j=-\frac{s}{2}}^{j+\frac{s}{2}} I(i, j) \quad (3.2)$$

その値を基に式 [?] より、二値化を行う。

$$I'(i, j) = \begin{cases} 1 & \text{if } (I(i, j) \leq S \times \frac{100-t}{100}) \\ 0 & \text{others} \end{cases} \quad (3.3)$$

## 3.2 2 つの閾値を用いた二値化処理

この処理は、単純二値化処理の閾値を 2 つに増やしたものであり、

### 3.3 Canny 法を用いたオブジェクト抽出

二値画像内において、物体は画素値が等しいピクセルの集合として表現でき、その重心位置  $G(G_x, G_y)$  は、画素値とピクセル座標より式 3.4 を用いて求めることができる。

$$\begin{aligned} G_x &= \frac{\sum_{p=1}^x \sum_{q=1}^y xI(p, q)}{\sum_{p=1}^x \sum_{q=1}^y I(p, q)} \\ G_y &= \frac{\sum_{p=1}^x \sum_{q=1}^y yI(p, q)}{\sum_{p=1}^x \sum_{q=1}^y I(p, q)} \end{aligned} \quad (3.4)$$

ここで、画像の原点は左上、 $I(p, q)$  はあるピクセル座標での画素値である。この式はオブジェクトが画像中に 1 つしかない場合のみ適応可能である。しかし、オブジェクトが 1 つのみの画像は稀であり、またカメラに付着した埃などにより背景に穴ができた場合も前述の式では、重心位置がずれてしまう。そこで、背景を除き画像内でピクセル集合（面積）が最大のものを目的のオブジェクトであると仮定し、その集合に対してのみ重心位置を求めることにする。

具体的には、まずラベリング処理により、背景からオブジェクトを分離し、それぞれの面積を計算する。その後、面積が最大のものに対して重心位置を計算する。

ラベリング処理とは、2 値画像上に点在している連結成分のそれぞれに固有の名前（番号など）を付ける処理であり、これにより連結成分の個数やそれぞれの特徴（面積など）を独立して計算可能である。また、連結成分とは、図 3.2 に示すように中心画素とその周囲のいくつかの画素が同値で存在する領域を指し、連結の種類には 4 連結と 8 連結がある。この 2 つの連結性




Fig.3.2. 4 connections and 8 connections

のうち、どちらか一方を背景、他方を検出したい物体に適用することで、背景とオブジェクトの境界付近にあるピクセルの孔の影響を抑え、それらを分離することができる。本アプリケーションでは、デフォルトで 8 連結をオブジェクトに適用している。

分離された個々のオブジェクトの面積は、それに内包されるピクセル数を数えることで求めることができる。そして、面積が最も大きい集合の画像全体に対する重心位置  $G'(G'_x, G'_y)$  は

次式で求められる.

$$\begin{aligned} G'_x &= \frac{\sum_{p=1}^x \sum_{q=1}^y x I'(p, q)}{S_{max}} \\ G'_y &= \frac{\sum_{p=1}^x \sum_{q=1}^y y I'(p, q)}{S_{max}} \end{aligned} \quad (3.5)$$

ここで,  $I'$  は次の条件を満たす画素値であり,  $S_{max}$  は面積の最大値である.

$$I'(i, j) = \begin{cases} 1 & \text{if } (I(i, j) \in S_{max}) \\ 0 & \text{others} \end{cases} \quad (3.6)$$



## 第 4 章

# 人工知能

### 4.1 人工知能

人工知能 (AI : Artificial IntelligenceI) は, 「どのようなデータを, どのようなアルゴリズムで処理すれば, 人間のような知能 (認識・処理・判断など) を実現することができるのか」について研究する分野であり, 1947 年にアラン・チューリングによってその概念が提唱された。

現在の AI に関する技術 (AI 技術) や応用分野については, 文献 [4] が詳しいので, そちらを参照されたい。

### 4.2 機械学習

機械学習とは, 「ルール of 記述が難しい問題 (例えば 1 枚の画像から人の顔を見分ける問題)」に対して, 人間がルールを決めるのではなく, コンピュータ自体にルールを発見させる手法」である。機械学習の問題は, 「分類問題」と「回帰問題」に大別することができる。分類問題とはデータがどのクラスに属するか, という問題である。例えば, 人の写った画像から, その人が男性か女性かのどちらであるかを分類するような問題が分類問題に相当する。一方, 回帰問題は, ある入力データから, (連続的な) 数値の予測を行う問題である。例えば, 人の写った画像から, その人の体重を予測するような問題が回帰問題に相当する。

機械学習において, コンピュータがルールを発見するまでの過程を「学習」, 発見されたルールをモデルといい, このモデルを用いて画像や音声などの判定 (認識) を行う。学習の主なタイプとしては, 以下の 3 つが挙げられる。

- 教師あり学習
- 教師なし学習
- 強化学習

今回用いた学習方法は, 教師あり学習のみであるため, 本節では, 教師あり学習に絞って簡単に説明する。教師あり学習とは, 学習用データすべてにあらかじめ正解となるラベルが振られており, 出力とラベルとを比較し, その誤差が小さくなるようルールを探していく方法である。教

教師あり学習は、分類問題と回帰問題に対してよく用いられる。分類問題とは、入力データがどのグループに属するかを予測する問題であり、例えば、メールをスパムと非スパムに分けるものや、Web ページの内容に応じて、「スポーツ」や「政治」などのジャンルに分類するものが挙げられる。また、回帰問題とは、連続した数値における予測を行う問題であり、株価予測や人の年齢予測などに用いられる。

機械学習の分類は、文献 [5] が詳しいので、そちらを参照されたい。

### 4.3 深層学習

深層学習とは、人や動物の脳の神経回路をモデルにした、多層のニューラルネットワークによる機械学習の手法であり、画像認識や言語処理、ゲームなど幅広い分野で応用されている。この技術のバックグラウンドは、図 4.1 に示すような、ニューラルネットワークと呼ばれる機械学習手法に支えられている。




Fig.4.1. NeuralNet

### 4.4 ニューラルネットワーク




Fig.4.2. 単純二値化処理

ニューラルネットワークとは、人間の脳内にある神経細胞（ニューロン）によって作られ

る神経回路網を真似て作られた数理モデルである。人間の脳は、図??(a)に示すようなニューロンが多数結合して回路網を形成している。そして、個々のニューロンは図??(b)に示すように電気信号の入力側ニューロンから電気信号を受け取って蓄積し、ある閾値を超えると、関連ニューロンに電気信号を伝達する。この閾値を超えて関連ニューロンへ電気信号が伝達されることを”発火”といい、またニューロンどうしの接続のことを”シナプス”という。シナプス強度はニューロンの組み合わせによって異なっており、強度が高いほど伝達させる信号の強度も高くなる。このニューラルネットワークの基礎となるモデルは、1943年に神経生理学者の W. McCulloch と数学者の W. Pitts によって提唱された [], そして、1957年 F. Rosenblatt により、学習可能なニューラルネットワークとして”パーセプトロン”が開発された。

#### 4.4.1 パーセプトロン

パーセプトロンは、図 4.3[a] に示すような構造を持ち、 $n$  次元空間内における点が 2 クラスに線形分離可能な場合、有限の試行回数で確実に分類できる。すなわち、この機械は分類問題の一部を解くことができる。その一例を図 4.3[b] に示す。ここで、それぞれの点の座標はクラス分けされる対象の属性または特徴を表す。また線形分離可能とは、その 2 クラスが、単純な線形超平面 (2 次元においては直線、3 次元空間においては平面、そして  $n$  次元空間においては  $(n-1)$  次元平面) で互いに分離できる場合をいう。

パーセプトロンの最終的な出力は、入力ベクトルと重みベクトルの外積和を活性化関数で二値化したものになる。例えば、入力ベクトルが 2 つの場合、この入力ベクトルと重みベクトルの外積和は次式で求められる。

$$h(\mathbf{x}) = w_1x_1 + w_2x_2 + b$$

ここで、 $b$  はバイアスと呼ばれ、後に説明する活性化関数において出力信号が 1 を出力する度合いを調整するパラメータとして機能する。パーセプトロンにおいては一般的にバイアスは  $b = 1$  を入力とする。またパーセプトロンは、入力信号に 1 対 1 で対応する重み  $\mathbf{w} = (w_0, w_1, w_2, \dots, w_n)$  をもち、その重みは、各信号の重要性をコントロールする要素として働く。すなわち、この重みはシナプスの結合強度を表し、値が大きいほど、その重みに対応する信号の重要性が高くなる。前述の式を  $w_0 = b, x_0 = 1$  として一般化すると、

$$\begin{aligned} h(x) &= w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n \\ &= \sum_{i=0}^n w_i x_i \\ &= \mathbf{w}^T \mathbf{x} \end{aligned} \tag{4.1}$$

となり、 $h(\mathbf{x})$  の値が、活性化関数 (式 4.2) における閾値  $\theta$  以上であれば、パーセプトロンの出力は 1 であり、0 より小さければその出力は 0 である。

$$y'(h(x)) = \begin{cases} 1 & (h(x) \geq \theta) \\ 0 & (h(x) < \theta) \end{cases} \tag{4.2}$$




Fig.4.3. パーセプトロンの構造と結果

入力画像など二次元で表される場合、その全体の入力および重みベクトルは以下の式で表される。

$$\begin{aligned}\mathbf{x} &= (x_{11}, x_{12}, \dots, x_{1j}, \dots, x_{1n}, x_{21}, x_{22}, \dots, x_{ij}, \dots, x_{Nn})^T \\ &= (\mathbf{x}_1^T, \mathbf{x}_2^T, \dots, \mathbf{x}_i^T, \dots, \mathbf{x}_N^T)^T\end{aligned}$$

$$\begin{aligned}\mathbf{w} &= (w_{11}, w_{12}, \dots, w_{1j}, \dots, w_{1n}, w_{21}, w_{22}, \dots, w_{ij}, \dots, w_{Nn})^T \\ &= (\mathbf{w}_1^T, \mathbf{w}_2^T, \dots, \mathbf{w}_i^T, \dots, \mathbf{w}_N^T)^T\end{aligned}$$

パーセプトロンの目標は、入力がクラス 1 に属しているとき出力が 1、クラス 0 に属しているとき出力が 0 となるような重み  $\mathbf{w}$  の集合を見つけることであり、その重みは、式 4.4 で表されるパーセプトロン学習則に従い、自動的に変更される。

$$\mathbf{w}_j^{new} = \mathbf{w}_j^{old} + \Delta \mathbf{w}_j \quad (4.3)$$

ここで  $\Delta \mathbf{w}_j$  は、正解クラスラベル  $y$ 、推定されたクラスラベル  $y'$ 、学習率  $\eta (0 \leq \eta \leq 1)$  を用いて、以下のようにあらわすことができる。

$$\Delta \mathbf{w}_j = \eta (y - y') \mathbf{x}_j^i \quad (4.4)$$

パーセプトロンの発明に続いて Rosenblatt は、線形分離可能なクラスが与えられると、パーセプトロンは、そのクラスを分離する重みベクトルを有回の学習で作り出すこと（そのパターンのクラス分け作業を完璧に  $(y - y') = 0$  で達成する）を証明した。この証明は重みの初期値に関係なく成り立つ。

#### 4.4.2 パーセプトロンの限界

Rosenblatt による証明は、ニューロコンピューティングの分野に大きな興奮を巻き起こしたが、2 クラスが単純な線形超平面で分離可能な場合のみという制限は残されたままであった。1969 年、M. Minsky と S. Papert により著書”パーセプトロン”にて、排他的論理和 (XOR)

論理関数 ( $f(0,0) = f(1,1) = 0, f(0,1) = f(1,0) = 1$  となる関数) を実現できないばかりか、他の多くのそのような述語関数も実現できないことを証明した。XOR 関数の出力を二次元平面上にプロットすると図 4.4 のようになる。この出力は線形分離不可能であり、分離を行うためには、パーセプトロンを非線形問題に対応できるよう拡張する必要があった。




Fig.4.4. XOR の出力とパーセプトロンの計算不可能性

#### 4.4.3 ADALINE(Adaptive Liner Neuron)

パーセプトロンが開発されて数年後、B. Widrow と彼の大学院生たちにより、ADALINE(Ada) と呼ばれるパーセプトロンの改良版が発明された。ADALINE は、図 4.5 に示す通り、出力の二値が 1 もしくは -1 であること、学習則に平均二乗和誤差を用いたことがパーセプトロンと異なる、




Fig.4.5. ADALINE の構造

#### 4.4.4 多層パーセプトロン

非線形問題を扱うために、1986 年 D. Rumelhart によって考案されたニューラルネットワークが多層パーセプトロンである。多層パーセプトロンは、入力層、出力層、そして中間層 (隠れ層) で構成されており、入出力層と隠れ層 1 層の場合が最も単純な構造である。また、各層は内部にいくつかのノードと呼ばれる処理要素を持ち、層ごとにその機能が異なる。

入力層のノードは、自信と接続されているすべてのノードに対して、同じ入力データを伝達する役割を持つ。隠れ層は、パーセプトロンと同様の構造を持つが、活性化関数に非線形関数を用いている。

## 4.5 コスト関数

学習能力を持ったを持った多くの（すべてではない）ニューラルネットワークにおいて、学習は、処理要素の要素の重みの変更を通して行われる。そして、重み訓練を行うニューラルネットワークにとって、その挑戦目標は、希望のネットワーク性能を与える位置に、重み  $\mathbf{w}$  を導く学習則を開発することである。この学習則の多くは、はっきりとした目標のもとに定式化される。一般に多く見かけるタイプの目標は、ニューラルネットワークの平均 2 乗和誤差や、○○のような全体的コストまたは評価関数を最小または最大にすることである（このような学習則は性能学習 (performance learning) と呼ばれるカテゴリに属する）。ある時間区間の入力信号の平均（または平均以外の性質）を学習するような、特定のコスト関数の最適化を目標としない学習則は、典型的な行動学または数学の用語で表すことができる目標を持つ（これはフィルタ学習 (filter learning) カテゴリに属する学習則の目標である）。ここでは、実験に関係のある、性能学習について説明する。

例えばパーセプトロンの場合、4.4.1 に示したパーセプトロン学習則において、 $(\mathbf{y} - \mathbf{y}' = 0)$  を達成する重みベクトル  $\mathbf{w}$  を見つけることが目標である。この式 4.4 は以下の Hebb の推定した生物学的学習則 (Hebb の学習則) より導くことができる。

$$\mathbf{w}^{new} = \mathbf{w}^{old} + \mathbf{y}_k \mathbf{x}_k^T \quad (4.5)$$

この学習則は、

## 4.6 畳み込みネットワーク

## 第 5 章

# 実機による動作実験

### 5.1 Dobot

TechShare 社が販売している Dobot Magician(Dobot) は, 4 自由度のロボットアームでありエンドエフェクタを取り換えることによって 3D プリンタのような積載加工, エンドミルによる切削加工ペンツールを使った印字などが行える. Dobot の質量と可搬質量はそれぞれ 3.4kg と 500g であり, 位置繰り返し精度は 0.2mm と教育ロボットとしては優れている. また Dobot 社より, C や MFC(Microsoft Foundation Class), Python など複数のプログラミング言語で API が提供されており, 個人でプログラムを組む際の敷居も低い. 今回は, その中の Python API を統合開発環境である Visual Studio2019 上に実装し, Dobot 本体を動作させるプログラムの開発を行った. API とはあるコンピュータプログラム (ソフトウェア) の機能や管理するデータなどを, 外部の他のプログラムから呼び出して利用するための手順やデータ形式などを定めた規約のことである. 今回はその中から Dobot 本体の姿勢を取得するための `GetPose()` また, Python に標準で搭載されている GUI 作成キットである Tkinter を用いて, 開発した動作プログラムを簡単に扱えるよう Dobot 制御用のユーザインタフェースの作成も行った.

### 5.2 学習データ

### 5.3 実験結果

## 第 6 章

### 今後の方針



## 謝辞

本研究は，山口東京理科大学大学院基礎工学研究科基礎工学専攻で行われたものである．

## 参考文献

- [1] 井尻善久, F. Drigalski, “産業用ロボットの進化によるものづくりの近未来”, 日本ロボット学会誌, Vol. 37, No. 8, pp. 5-8, 2019.
- [2] N. Otsu, “A Threshold Selection Method from Gray-Level Histograms.”, IEEE Transactions on Systems. Man. and Cybernetics, Vol. 9, No. 1, pp. 62?66, 1979.
- [3] D. Bradley, G. Roth, “Adapting Thresholding Using the Integral Image”, Journal of Graphics Tools, Vol. 12, No. 2, pp.13?21, 2007.
- [4] <https://www.ai-gakkai.or.jp/resource/aimap/>
- [5] 神寫敏弘, 鹿島久嗣, “機械学習分野の俯瞰と展望”, 人工知能学会誌, Vol. 34, No. 6, pp. 905-915, 2019.
- [6]